
What features are correlated to the length of sentence?

- Studying Chinese court documents from wenshu.gov.cn.

Violet Yao



Structure of Presentation

- Data collection
- Dataset Construction
- Analysis
- Results
- Challenges
- Tools
- Next Steps: How would you take this project forward?
- Advertising

Data Collection

Data source: http://wenshu.court.gov.cn/



Data size: collected ~ 1,000,000 cases, ended up using 150,000

```
In [36]: df_new = df_new.sample(n=150000, random_state=42)
In [37]: df_new.to_csv("data.csv")
```

Data Collection - Web Scraping


print("detail_page: ", result)

return result

```
class Wenshu:
# url : parse.ParseResult = parse.urlparse("http://wenshu.court.gov.cn/website/parse/rest.q4w")
   url = parse.urlparse("http://wenshu.court.gov.cn/website/parse/rest.q4w")
# url = parse.ParseResult
   def init (self):
                                                                                                             Cookies required
                                                                                                                                                                                           Decrypt query result
       self.session = requests.Session()
       self.session.headers.update({
           "User-Agent": "Mozilla/5.0 (Macintosh: Intel Mac OS X 10 14 6) AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/76.0.3809.132 Safari/537.36".
   def _request(self, data: dict) -> requests.Response:
       response = self.session.post(self.url.geturl(), data=data)
      if response.status code != 200:
          raise Exception(response.status code)
      ison data = response.ison()
      plain_text = des3decrypt(cipher_text=json_data["result"]
                            kev=ison data["secretKev"].
                            iv=datetime.now().strftime("%Y%m%d"))
      result = ison.loads(plain text)
                                                                                                 Use Docker splash
                                                                                                                                                                                            Receive encrypted
      return result
   def list page(self, word):
        ""input query, return page list"""
                                                                                                 to get cookies to
                                                                                                                                                                                            query result
      print("Page id: \n", PageID())
                                                                                                 simulate a logged in
                                                                                                                                                                                            message from
      # the maximum size for one page is 1000
      data = {
          "pageId": PageID(),
                                                                                                                                                                                           Javascript
          "sortFields": "s50:desc",
"ciphertext": CipherText(),
                                                                                                 session
          "pageNum": 1,
           "pageSize": 1000
           "queryCondition": json.dumps([{"key": "s42", "value": "2018"}
                                    {"key": "s33", "value": "上海市"},
                                    {"key": "s8", "value": "02"},
{"key": "s45", "value": word}]),
          "cfg": "com.lawyee.judge.dc.parse.dto.SearchDataDsoDTO@queryDoc"
            RequestVerificationToken": RequestVerificationToken(24).
      result = self, request(data)
       print("list_page: ", result)
      id_lst = list(result['relWemshu'].keys())
       print(id 1st)
                                                                                                                                      Find a static Javascript, but
      print("Query word: ", word)
      print("length: ", len(id_lst))
      print()
                                                                                                                                                   Require cookie
      return id_lst
   def detail_page(self, doc_id):
       """input
                                                                                                                                                   Query words has to be
      print(doc_id)
      data = {
          # ORIGINAL: 4e00b8ae589b4288a725aabe00c0e683
           "docId": "4e00b8ae589b4288a725aabe00c0e683"
                                                                                                                                                   encrypted
          "docId": doc id.
          "ciphertext": CipherText(),
          "cfg": "com.lawyee.judge.dc.parse.dto.SearchDataDsoDTO@docInfoSearch",
           RequestVerificationToken": RequestVerificationToken(24).
      result = self, request(data)
```

Data Collection

Raw data format: a JSON file per case




A sample raw data json:

Key-value pairs


{"s1": "□某某危险驾驶一审刑事判决书", "s2": "上海市虹口区人民 法院", "s3": "925", "s5": "1d50fdb5203d4094bd05a87a00ef416d", "s6": "01", "s7": "(2017) 沪0109刑初1096号", "s8": "刑事案件", "s9": "刑事一审", "s31": "2018-01-09", "s41": "2018-02-01", "s22": "上海 市虹口区人民法院n刑事判决书\n(2017) 沪0109刑初1096号", "s23": "上海市虹口区人民检察院以沪虹检诉刑诉[2017]XXXX号起 诉书指控被告人史某某犯危险驾驶罪,于2017年12月29日向本院提 起公诉。本院依法适用简易程序,实行独任审判,公开开庭审理了 本案。上海市虹口区人民检察院指派检察员周某出庭支持公诉,被 告人史某某到庭参加诉讼。现已审理终结", "s25": "上海市虹口区人 民检察院指控:被告人史某某于2017年9月1日凌晨3时20分许,酒后 驾驶牌号为鄂A7XXXX的小轿车, 行驶至本市虹口区汶水东路、凉 城路东约50米处时被民警查获。经现场呼气式酒精测试,酒精含量 为135mg/100ml。后被告人史某某被带至医院提取血样。案发后, 经上海润家生物医药科技有限公司司法鉴定所鉴定:送检史某某的 血样中检出酒精含量为116.3mg/100ml。\n上述事实, 被告人史某 某在开庭审理过程中无异议,并有证人边某的证言,上海市公安局 虹口分局出具的《呼气式酒精则试仪结果打印单》、《当事人血样提 取登记表》、《案发经过》、《查获经过》及上海润家生物医药科技有 限公司司法鉴定所出具的《司法鉴定意见书》等证据证实, 足以认 定", "s26": "本院认为, 被告人史某某在道路上醉酒驾驶机动车, 其 行为已构成危险驾驶罪。上海市虹口区人民检察院指控被告人史某 某犯危险驾驶罪罪名成立。被告人史某某到案后能如实供述自己的 罪行, 日能认罪认罚, 并在本院亩理期间预缴了罚金, 确有悔罪表

Dataset Construction



Selected Keys: fact, relevant articles, accusation types, penalty (money, sentence length, if it is death penalty of life imprisonment)

Modeling Overview



Modeling - Feature Matrix construction

Recall research question:

What features correlate to the length of sentence?

Numeric

Categorical

```
In [63]: df["accusation"].value_counts()
Out[63]: ['[走私、贩卖、运输、制造]毒品']
                                                                                            4140
         '抢劫', '盗窃']
                                                                                       2684
         '盗窃'
                                                                                      2209
                                                                                         1935
                                                                                         1876
          [生产、销售]不符合安全标准的食品']
                                                                                          1872
                                                                                        1866
                                                                                      1864
                                                                                       1863
                                                                                       1859
                                                                                        1851
                                                                                        1849
                                                                                           1849
                                                                                          1842
                                                                                            1842
               强迫、引诱、容留、介绍1卖淫', '[引诱、容留、介绍1卖淫']
                                                                                                    1837
                                                                                                    1834
                                                                                                1826
```

Melting & One hot encoding: pandas.get dummies()

Text

Modeling - feature matrix construction - Text

Raw text

Using package Jieba

'安阳县人民检察院指控:2009年至2012年,被告人杨1某利用其在洛阳市 中级人民法院工作, 先后担任民某副庭长、执行局副局长的便利条件, 通 过让本院同事在审理案件过程中为案件当事人提供帮助, 非法收受他人 贿赂现金及购物卡共计36.8万元,个人实得32.8万元。案发后赃款已退。 具体如下:1、2009年至2011年期间,被告人杨1某利用其在洛阳市中级人 民法院工作, 先后担任民某副庭长、执行局副局长的便利条件, 让同院法 官王某在审理洛阳河科大齿轮制造有限公司诉洛阳科锐机电设备有限公 司技术合同纠纷一案和洛阳鸿拓重型齿轮箱有限公司诉洛阳科锐机电设 备有限公司技术合同纠纷一案时, 为原告提供帮助, 先后四次非法收受付 某某现金19.5万元和购物卡1万元, 杨1某将其中4万元送给王某。2、2011 年9月至2012年3月份期间,被告人杨1某利用其先后担任民某副庭长、执 行局副局长的便利条件, 多次打招呼让民某法官杨某、王某甲在审理河南 红旗渠建设集团有限公司诉嵩县中医院工程欠款纠纷一案中给予原告照 顾, 非法收受朱某某现金15万元及购物卡1.3万元。为认定上述事实, 公 诉机关提供了被告人供述、证人证言、书证等证据. 并据此认为被告人的 行为触犯了《中华人民共和国刑法》××××、××××第(一)项、××. 应当以×× 罪追究其刑事责任。提请本院依法判处。'

Tokenized text

"['安阳县', '人民检察院', '指控', ':', '2009', '年', '至', '2012', '年', ', ', '被告人', '杨', '1', '某', '利用', '其', '在', '洛阳市', '中级', '人民法院', '工作', ', ', '先后', '担任', '民某 ','副庭长','、','执行局','副局长','的','便利','条件',',','通过','让','本院','同事',' 在', '审理案件', '过程', '中为', '案件', '当事人', '提供', '帮助', ', ', '非法', '收受', '他 人', '贿赂', '现金', '及', '购物', '卡', '共计', '36.8', '万元', ', ', '个人', '实得', '32.8', '万 元', '。', '案发后', '赃款', '已退', '。', '具体', '如下', ':', '1', '、', '2009', '年', '至', '2011'、'年'、'期间'、'、', '被告人', '杨', '1', '某', '利用', '其', '在', '洛阳市', '中级', '人民 法院', '工作', ', ', '先后', '担任', '民某', '副庭长', '、', '执行局', '副局长', '的', '便利', ' 条件'、'、'、'让'、'同院'、'法官'、'王某'、'在'、'审理'、'洛阳'、'河'、'科大'、'齿轮'、'制造'、' 有限公司', '诉', '洛阳', '科锐', '机电设备', '有限公司', '技术', '合同纠纷', '一案', '和 ','洛阳','鸿拓','重型','齿轮箱','有限公司','诉','洛阳','科锐','机电设备','有限公 司'、'技术'、'合同纠纷'、'一案'、'时'、'、', '为'、'原告'、'提供'、'帮助'、'、', '先后'、'四次'、' 非法','收受','付','某某','现金','19.5','万元','和','购物','卡','1','万元',',','杨', '1'. '某'. '将'. '其中'. '4'. '万元'. '送给'. '王某'. '。'. '2'. '、'. '2011'. '年'. '9'. '月'. '至'. '2012', '年', '3', '月份', '期间', ', ', '被告人', '杨', '1', '某', '利用', '其', '先后', '担任', 民某', '副庭长', '、', '执行局', '副局长', '的', '便利', '条件', ', ', '多次', '打招呼', '让民 某'.'法官'.'杨某'.'、'.'王某'.'甲'.'在'.'审理'.'河南'.'红旗渠'.'建设'.'集团'.'有限 公司', '诉', '嵩县', '中医院', '工程', '欠款', '纠纷', '一案', '中', '给予', '原告', '照顾', '.','非法','收受','朱','某某','现金','15','万元','及','购物','卡','1.3','万元','。', 为'.'认定'.'上述事实'.'.'.'公诉'.'机关'.'提供'.'了'.'被告人'.'供述'.'、'.'证人'.'证 言', '、', '书证', '等', '证据', ', ', '并', '据此', '认为', '被告人', '的', '行为', '触犯', '了', ' 项'.'、'.'×'.'×'.'.' '.'应当'.'以'.'×'.'*'.'罪'.'追究其'.'刑事责任'.'。'.'提请'.'本院'.' 依法'. '判处'. '。']"

Remove Stop words & punctuations

Tokenized text

"[安阳县', '人民检察院', '指控', ':', '2009', '年', '至', '2012', '年', ', '被告人', '杨', '1', '某', '利用', '其', '在', '洛阳市', '中级', '人民法院', '工作', ', '先后', '担任', '民某', '副庭长', '心', '执行局', '副局长', '的', '便利', '条件', ', ', '通过', '让', '本院', '同事', '在', '审理案件', '过程', '中为', '案件', '当事人', '提供', '帮助', ', '非法', '收受', '他人', '贿赂', 现金', '及', '购物', '卡', '共计', '36.8', '万元', ', '个人', '实得', '32.8', '万元', '。', '案发后', '赃款', '已退', '。', '具体', '如下', ':', '1', '、', '2009', '年', '至', '2011', '年', '期间', ', ''被告人', '杨', '1', '某', 利用', '其', '在', '洛阳市', '中级', '人民法院', '工作', ',


Remove Stopwords & punctuations

A sample code


```
add_punc=', 。、[] "":; () 《》''{}?!⑦()、%^>°C:.""^---=&#@\times'
all_punc=punctuation+add_punc
def sentence_cut(x):
    x = ' '.join(x)
    x=re.sub(r'[A-Za-z0-9]|/d+','',x) #delete numbers and English
letters
    testline=x.split(' ')
    te2=[]
    for i in testline:
        te2.append(i)
        if i in all_punc:
              te2.remove(i)
    return te2
```



Choose ~200 words with high frequency




Modeling Overview



Result


Baseline Model - predicting all to be the mean



VS

Linear Regression Model


- Using 400+ features



Features: amount of fine (numeric); accusation types, relevant articles, words in tokenized fact (one hot encoding)

Challenge - Web Scraping

• Wenshu website: no public rules over web scraping & no api for data



Tools Overview

Web Scraping



Data Manipulation




Data Visualization



Seaborn







Next Steps

- Train a more robust model
 - Include more features
- Implications
 - Of Get a model, so what?
- Questions

Advertising

- TextXD starts tomorrow
 - O https://www.textxd.org/
- Data Discovery Program
 - A perfect way to recruit free undergrad RAs
 - https://data.berkeley.edu/research/discovery
- Looking for RA opportunity
 - Broadly interested in Natural Language Processing, Legal Studies, and Al Safety
 - Resume at https://violetyao.github.io/
 - o Email <u>violetyao@berkeley.edu</u>